面向隐私保护的分布式 AI 模型增量训练更新方法

名称	内容
项目名称	ID-009 AI 金融大模型评测平台
文档类型	模块设计报告
模块代号	PPDIT(Privacy-Preserving Distributed Incremental Training)
设计日期	2026 年 11 月 1 日
适用前提	被测目标模型均为公共厂商 API 模型,不涉及本地模型与自训练模型

1. 设计背景与动机

1.1 现状:业务专项分数是平台可信度的最薄弱环节

ID-009 已形成"模型注册 → 评测调度 → 六能力域评分 → Pareto 图谱"的测算闭环,但"业务专项"域(权重 10%)的分数存在结构性缺陷:

1. **评测集缺位**——真实业务样本散落私域,受《个人信息保护法》《数据安全法》及 GDPR 约束不能出域;
2. **裁判缺位**——业务答案需领域知识评判,通用 LLM-as-Judge 打分不准;
3. **当前为画像模拟**——分数由画像 + 抖动生成,不反映真实表现。

对以分数为核心商品的平台,测不准的分数直接误导选型决策。

1.2 关键前提:被测对象不可训练

被测模型均为公共厂商 API 模型,"用私有数据改进被测模型"的全部路径被封死:

路径	为何不可行
本地权重微调	闭源:无权重、无梯度,不存在训练入口
厂商托管微调	须上传私有语料,隐私与合规不可接受
引入本地 / 自训练模型	与平台定位冲突

1.3 结论:训练测算的尺子,而非被测的模型

排除法可得,唯一可增量训练的对象是**平台自身的测算资产**,PPDIT 作用于三类:

训练对象	形态	增量含义
联邦评测	分布式评测协议(样本不出域)	私域样本持续新增,分数逐轮逼近真实
业务域裁判模型	轻量开源模型(2~7B)+ LoRA,平台工具资产	各方私有标注联邦训练,评分准确性持续进化
评分预测器	轻量预测模型	私有使用反馈联邦训练,为厂商新模型提供冷启动预估分

原始数据、标注、API Key 全部留在参与方域内;上行仅有差分隐私加噪、安全聚合掩码后的分数统计量与裁判增量。被测模型只被调用、不被改动。

---

2. 模块定位与业务闭环

2.1 业务闭环

PPDIT 是 ID-009 新增子模块,衔接既有闭环:报告发现业务域分数不可信(标记"模拟")→ 发起联邦评测 / 裁判训练 → 实测分回注既有评分结果 → 图谱由"模拟"升级为"实测"。**被测模型不变,变的是分数的质量与置信度。**

参与方侧为轻量客户端(Participant Agent),部署在数据持有方域内,持本方 API Key,对被测模型的调用不经平台。

2.2 四种应用方式

被测模型不可训练,结合点全部落在**分数的生产质量**上:

方式一:联邦评测——业务域分数的隐私化实测(主应用) 参与方本地以私有样本调用被测模型、本地裁判打分,仅上行 DP 加噪 + 掩码的分数统计量;聚合后写回既有业务域字段、按既有公式重算综合分——分数的存储与消费接口完全不变。

方式二:裁判模型联邦增量训练——分数准确性的持续进化 各方用私有标注对轻量裁判(2~7B + LoRA)本地 DP-SGD,增量经安全聚合形成新版本;裁判为平台工具资产,独立登记、不进被测模型目录,须通过公共**锚定回归集**验收方可激活。

方式三:评分预测器——厂商新模型冷启动预估 各方以私有使用反馈联邦训练轻量预测器,为新模型提供业务域预估分。图谱以空心点呈现,实测完成后替换为实心点。

方式四:分数置信度-隐私预算联合呈现 每个业务域分数携带来源标记(simulated / federated / predicted)与置信量(参与方数、样本覆盖、累计 ε),图谱渲染置信环——决策者可区分"画像猜的 87 分"与"三家机构两千条私域样本实测的 87 分"。

2.3 嵌入点选择:五个业务维度的逐一评估

评估标准:①不违背数据不出域;②不污染既有实体语义;③引用关系天然存在;④侵入量小。

候选维度	嵌入含义	评估	结论
模型注册中心	训练产物回注为新模型版本(v1.0 方案)	被测模型不可训练,"增量版本"无从产生;自产裁判入库会污染厂商目录的选型语义	**否决**,降级为只读上游
数据集管理	联邦数据集:仅登记元数据(能力域、参与方、样本量声明、快照指纹),样本永不入库	"登记指针、不落样本"化解上传风险,评测资产获得正式血缘节点	**落点之一(资产侧)**
评测任务调度	联邦任务共用任务表	生命周期冲突(单机秒级 vs 多方轮次)、1:1 结果约束冲突	**否决**(复用模式,不共用表)
评分结果	实测分数写回业务域分数字段	口径统一:实测分与其余五域同表同尺聚合,图谱零改动消费	**落点之二(分数侧)**
评分图谱	置信环 + 预估空心点	消费端终点,无实体承载	仅作呈现出口

结论——"双落点、一上游、一出口":数据集为资产落点,评分结果为分数落点;模型注册中心只读;图谱为呈现出口;入口在报告页业务域"模拟"标记处。

2.4 嵌入合理性

1. **必然性**:被测对象不可变,"增量训练"的只能是平台可支配的测算资产——约束下的唯一解,而非多方案择优;
2. **分数语义不变**:实测分写入既有业务域字段、按既有公式重算,模拟与实测、实测前后全部同尺可比;Pareto 与图谱对来源无感知;
3. **模型目录纯净**:注册中心是选型决策的事实来源,裁判与其同表会出现"裁判出现在被选型列表"的语义事故;裁判独立存放,模型目录零变更;
4. **登记指针、不落样本**:资产有正式血缘节点,样本量与快照指纹进入任务指纹,分数可复现、可审计;
5. **耦合最小**:相比共用评测任务表(状态机分叉、结果约束重构),双落点对既有实体接近零侵入,仅评分结果增加来源标记;
6. **触发与呈现对齐用户路径**:发现"分数是猜的"的现场即可发起实测;置信环让选型首次能区分"分数高"与"分数可信"。

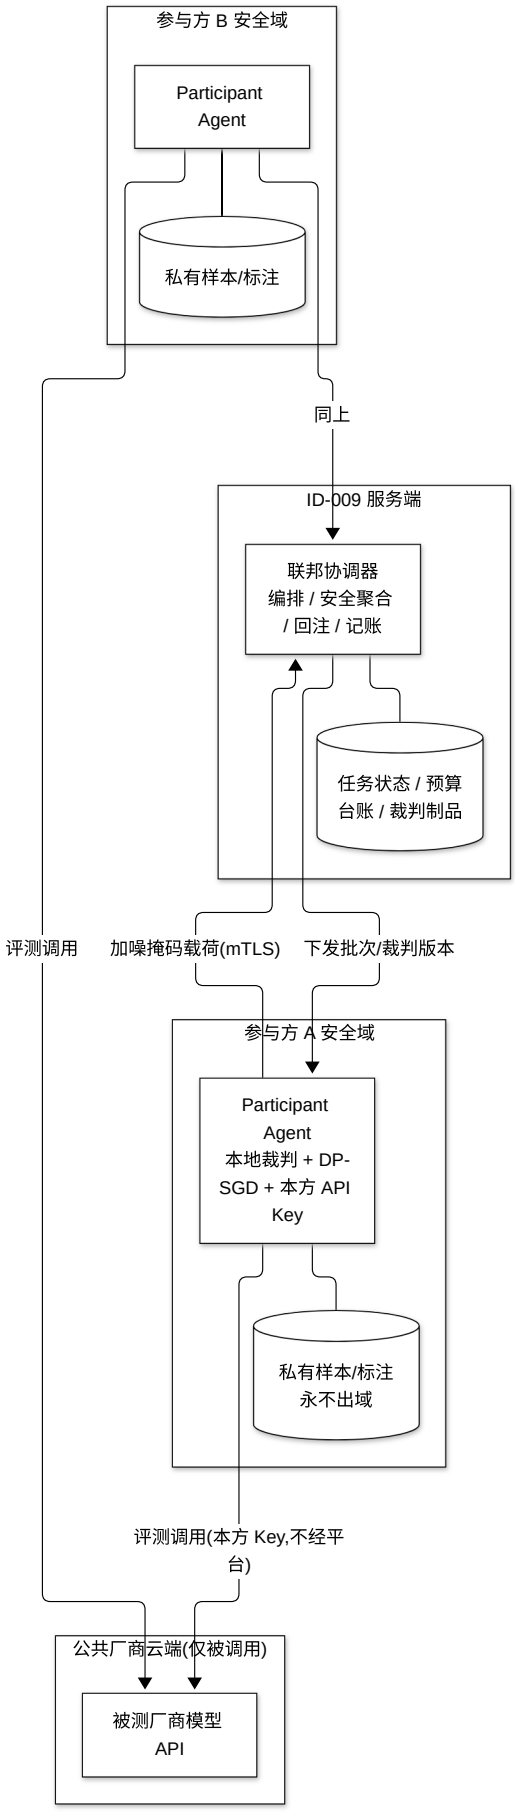
---

3. 总体架构设计

3.1 角色划分

角色	部署位置	职责	可见范围
协调器	ID-009 服务端	任务编排、批次下发、安全聚合、分数回注、裁判版本管理、预算记账	仅聚合后的统计量与增量之和
参与方代理	数据持有方域内	本方 Key 调用被测模型;本地裁判打分;裁判 LoRA + DP-SGD;加噪掩码上行	本方数据 + 全局裁判版本
被测厂商模型	厂商云端(外部)	仅被调用,不被改动	评测请求内容(厂商侧残余可见,见 3.3)
模型注册中心 / 评分管线	既有系统	只读上游 / 承接分数回注	—

3.2 架构与关键约束


参与方 B 安全域
Participant Agent
私有样本/标注
同上
ID-009 服务端
联邦协调器 编排 / 安全聚合 / 回注 / 记账
任务状态 / 预算 台账 / 裁判制品
评测调用
加噪掩码载荷(mTLS)
下发批次/裁判版本
参与方 A 安全域
Participant Agent 本地裁判 + DP-SGD + 本方 API Key
私有样本/标注 永不出域
评测调用(本方 Key,不经平台)
公共厂商云端(仅被调用)
被测厂商模型 API

关键约束:

- 原始数据零上行(仅加噪掩码后的统计量 / 裁判增量);
- 评测调用不经平台(query 对平台不可见);
- 安全聚合使单方上行对服务端不可见;
- 被测对象只读。

3.3 数据可见性边界

数据	参与方自身	其他参与方	平台	厂商
原始样本 / 标注	✓	✗	✗	调用时请求可见(厂商侧残余风险,无法根除,见 5.3)
单方统计量 / 增量(明文)	✓	✗	✗(仅见聚合和)	✗
聚合分数 / 裁判版本	✓	✓	✓	✗
被测模型权重	✗	✗	✗	✓

---

4. 执行流程

4.1 任务生命周期

三类任务(联邦评测 / 裁判训练 / 预测器训练)共用一套状态机:草拟 → 招募参与方(达最小参与方数就绪)→ 逐轮运行 → 完成 / 失败。与既有评测状态机同构(仅新增"招募"态),支持暂停、断点续跑、失败后重新招募;完成后联邦评测回注分数,裁判训练经锚定验收激活新版本。

4.2 数据设计要点

新增联邦任务、参与方、轮次、上行回执、隐私预算台账、裁判版本六类实体;既有实体仅两处轻量扩展(数据集增加联邦形态与元数据、评分结果增加来源与置信标记),模型目录零变更。关键原则:

- 上行回执只存摘要不存载荷;
- 任务指纹由七要素构成(被测模型 + 联邦数据集指纹 + 裁判基座 + DP 参数 + 算法 + 参与方集合 + 轮数),分数可复现、可审计;
- 裁判版本独立存放,不进被测模型目录;
- 对外接口沿用既有 GraphQL 入口与鉴权。

---

5. 可行性论证

5.1 业务可行性

1. **对症最薄弱环节**:业务域是六域中唯一无真实数据支撑的域,PPDIT 使其升级为私域实测、可信度可视化;
2. **约束下的唯一解**:常规路径均不可行(1.2 节),进化测算资产与平台"只测不训被测模型"的边界自洽;
3. **多租户契合**:平台用户本就是多组织形态,联邦范式与用户结构同构;
4. **冷启动价值**:预测器填补新模型选型窗口期的分数真空。

5.2 技术可行性

1. **插件边界内闭合**:PPDIT 作为 ID-009 插件的内聚子模块实现,引擎层契约不变,不新增容器;
2. **两项核心解耦**:被测目录零污染(注册中心只读)、分数口径零分叉(既有字段与公式回注);
3. **模式经过验证**:状态机、断点续跑、可复现指纹直接迁移自既有工程;新风险收敛到聚合与密码学协议,采用成熟库、不自研原语;
4. **API 接入天然兼容**:参与方本地调用与平台侧调用同属 API 接入语义,无需推理后端改造。

5.3 隐私与合规可行性

1. **四层正交互补**:联邦化消灭样本上行、LoRA 收窄传输面、DP 给出可证明 (ε,δ) 保证、安全聚合隐藏单方载荷;
2. **厂商侧可见性显式管理**:以 zero-retention DPA / 本地脱敏 / 合成孪生样本管理,可见性边界表(3.3 节)供合规审查;
3. **预算可举证**:ε 落库记账 + 硬门禁,对齐操作血缘审计要求。

5.4 成本可行性

维度	评估
服务端	仅统计聚合与记账,无 GPU,现有部署可承载
通信	统计量 KB 级;裁判 LoRA 单轮约 10~30 MB/方
参与方	裁判单卡消费级 GPU 可训可推;API 费用为参与方固有业务支出
开发	分阶段交付,首期以模拟联邦先行打通闭环

6. 演进路线

阶段	交付	隐私层
Phase 1(本期)	任务编排 + 状态机 + 模拟联邦评测 + 分数回注 + 置信环	预算台账(模拟值)
Phase 2	参与方代理落地:本地调用 + 本地裁判打分 + 统计量 DP 上行	联邦化 + DP
Phase 3	裁判联邦训练 + 安全聚合 + 鲁棒聚合 + 锚定验收 + 证书体系	全四层
Phase 4	评分预测器;抽象为 i-Core 公共能力	—

---

7. 总结

被测对象为公共厂商 API 模型,"增量训练被测模型"不存在合法路径。PPDIT 将隐私保护的分布式增量训练重定位为**训练测算的尺子**:联邦评测使业务域分数从画像模拟逼近私域实测,裁判联邦训练使评分准确性持续进化,评分预测器填补新模型冷启动真空。

嵌入遵循"**双落点、一上游、一出口**":数据集以"登记指针、不落样本"承载资产,评分结果以既有字段与公式回注,模型目录保持只读纯净,图谱以置信环呈现。全部私有数据与 API Key 留在参与方域内,上行载荷经 DP 与安全聚合双重保护,隐私预算落库可审计。

合理性收敛为一点:**平台的核心商品是分数,而业务域分数的质量瓶颈恰恰卡在"数据不能出域"——PPDIT 在不触碰被测模型、不移动任何私有数据的前提下,把平台最不可信的分数变成最有据可查的分数。**